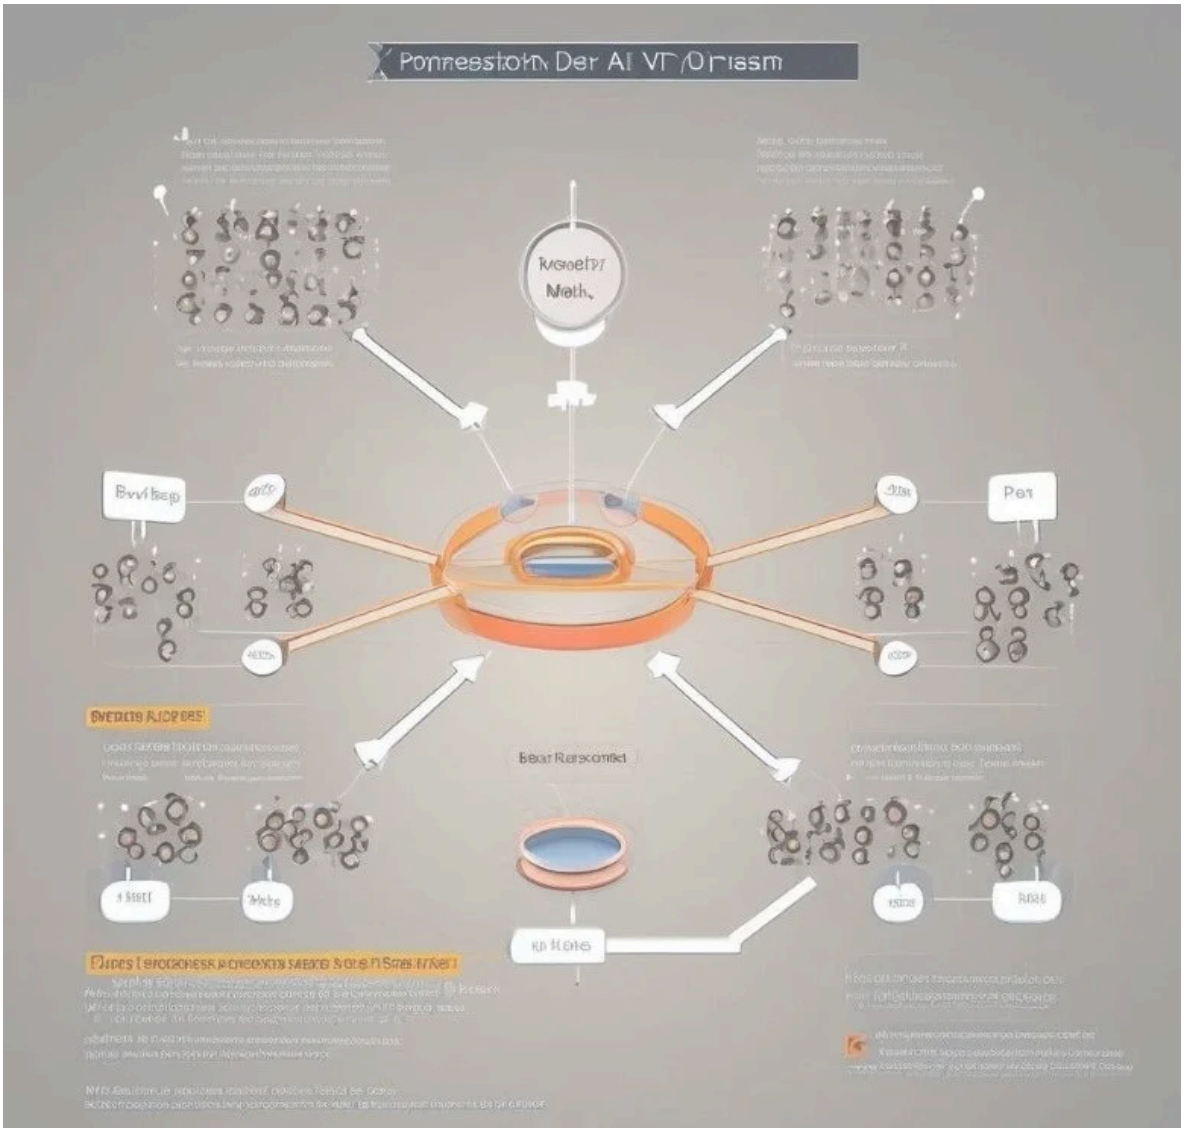
AI 进阶实战 | 走进大模型（LLM）+智能体（Agent）+提示词（Prompt）

Original 译点 每天译点晓知识 2024年08月14日 03:52

前言

人工智能（AI）不再只是科幻电影中的桥段，而是正以前所未有的速度改变着我们的世界。随着大规模语言模型（LLM）系列的崛起，结合高度智能的（Agent）与精心设计的（Prompt），AI 技术正步入一个全新的进阶实战阶段。

本文将带您深入探索这一前沿领域，揭秘如何运用 LLM 大模型、智能体 Agent 与提示词 Prompt，共同编织出未来智能生态的宏伟蓝图。

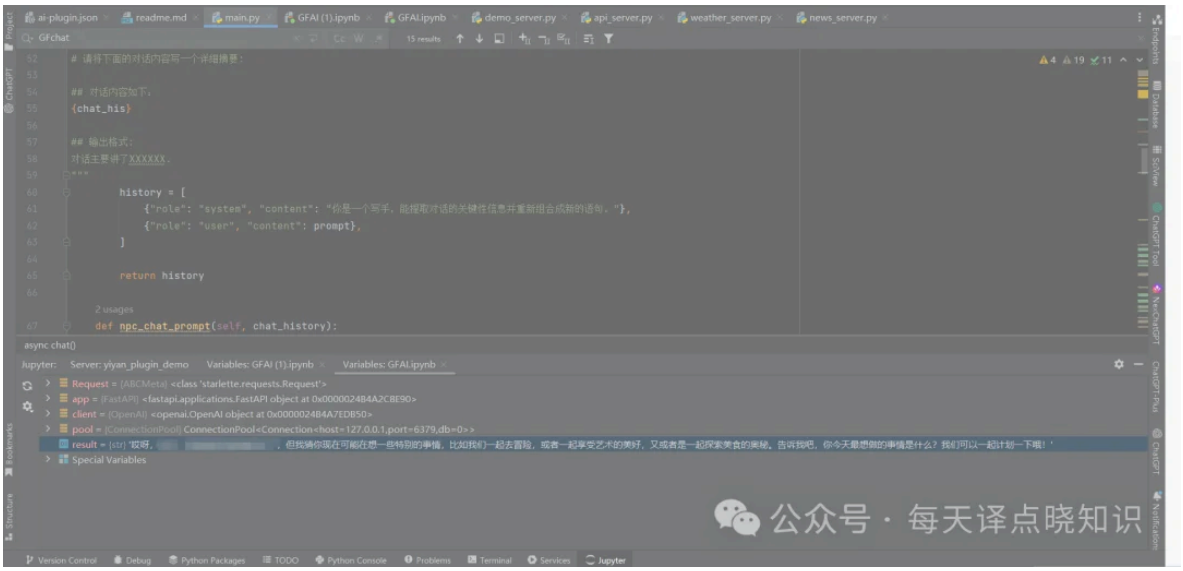


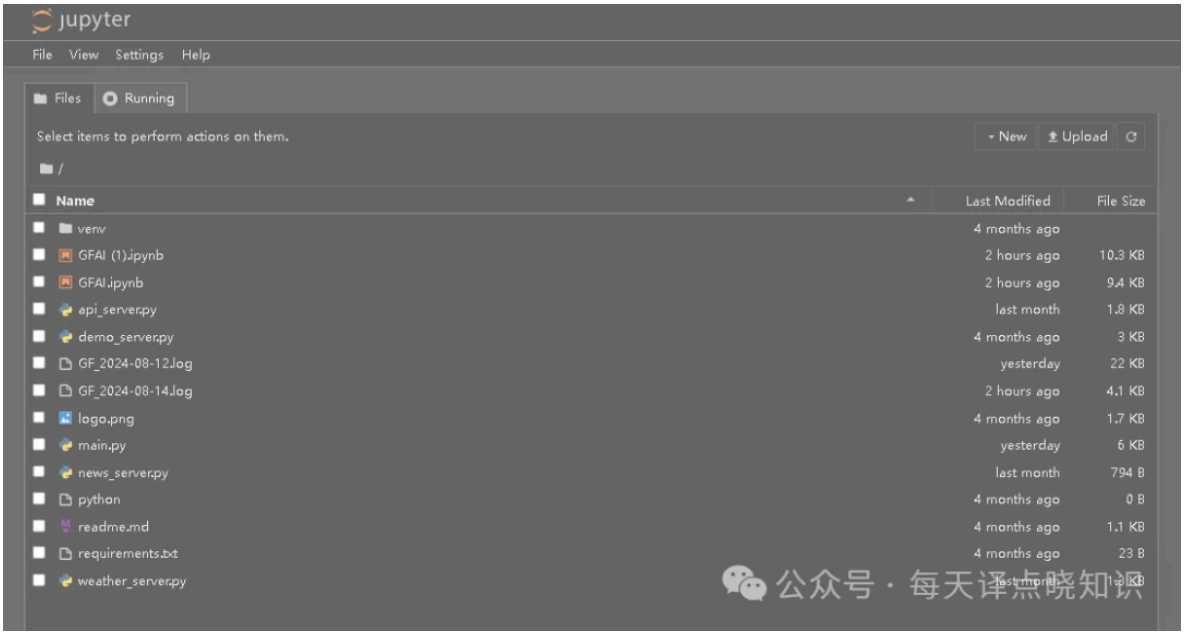
与你一起解锁 LLM 大模型+智能体 Agent +精妙 Prompt：实战进阶，重塑未来智能生态！

【打造一款带记忆功能的AI智能通用问答产品】

No.1 实操环境准备

PyCharm 编辑器+Python 编程神器 Jupyter Notebook（可以在线调试-便捷）





FastAPI（极简、快速、高性能Web框架）+redis（数据缓存、存储服务）

```
pip install fastapi uvicorn openai redis
```

```
127.0.0.1:6379> hset  GFhistory history "{['hhhhhh','sgsgsgsgsg']}"
1
127.0.0.1:6379> hgetall GFhistory
history
{['hhhhhh','sgsgsgsgsg']}
127.0.0.1:6379>
```

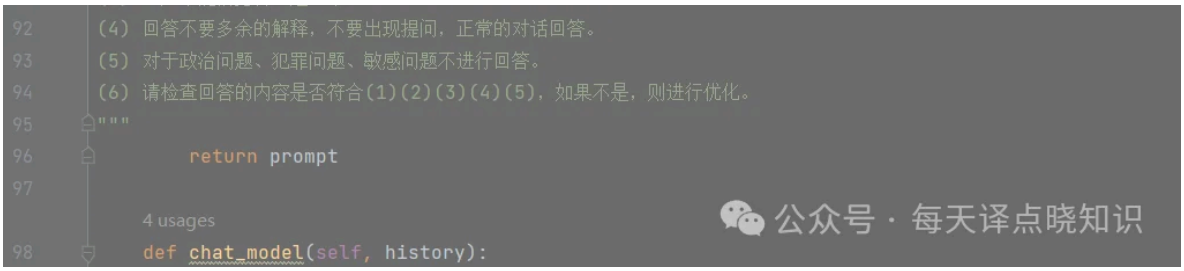
设置如上-会话存储的 hash 结构：具体的 value 即回答的 N 条真实记录（可结合实际会话ID进行关联），到这里准备工作就已经完成了。

No.2 项目工程搭建

建立 Python Project：这里 LLM 采用 KIMI（moonshot）：

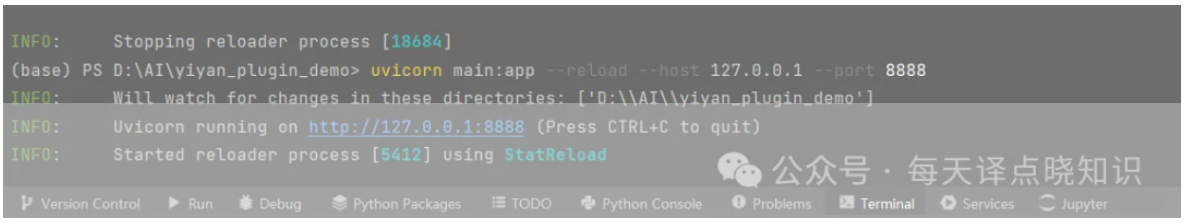


模型版本选择（moonshot-v1-32k）+ 精妙提示词（prompt）设定（高质量的提示词可以帮助模型理解人类的目标，换言之人类直接向模型提出命令或一条通向目标的推理路径。设计一个更有效的交互策略，使得模型生成的内容能符合人的意图和需求）

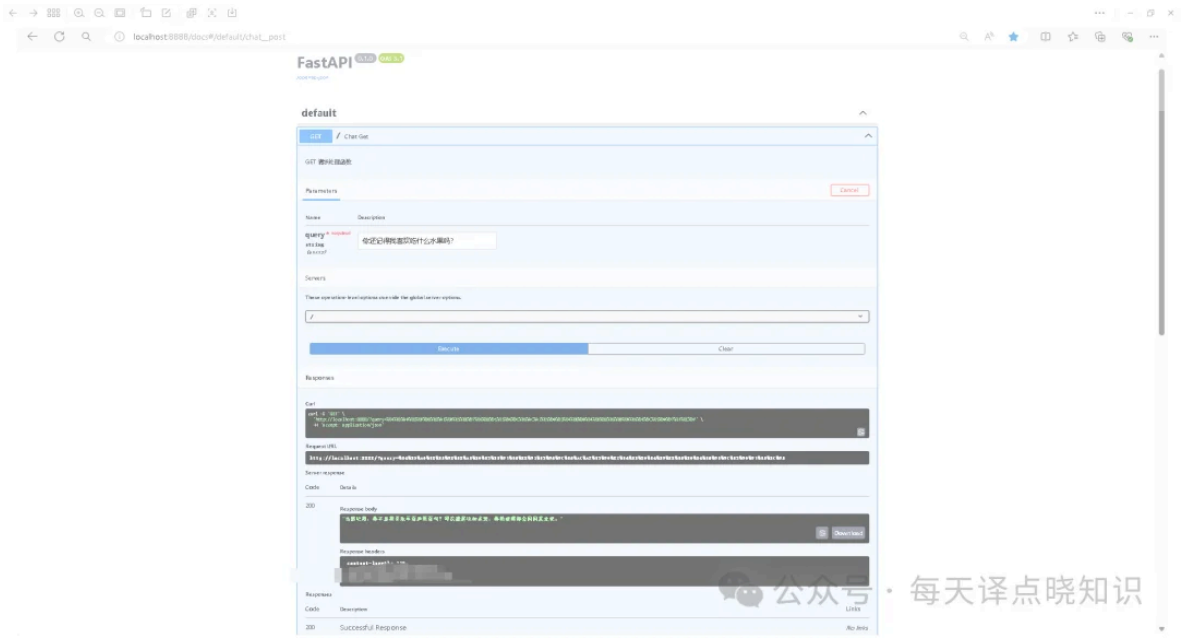


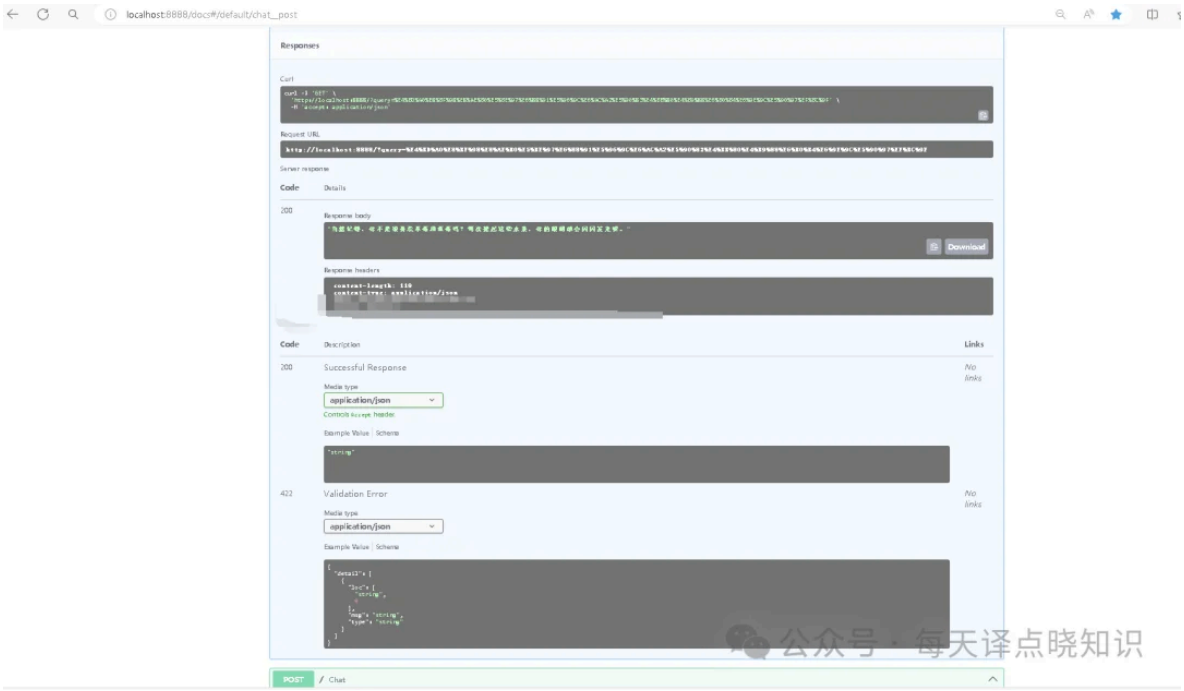
输入如下命令，启动开发服务器并在代码变更时自动重新加载。

```
uvicorn main:app --reload --host 127.0.0.1 --port 8888
```

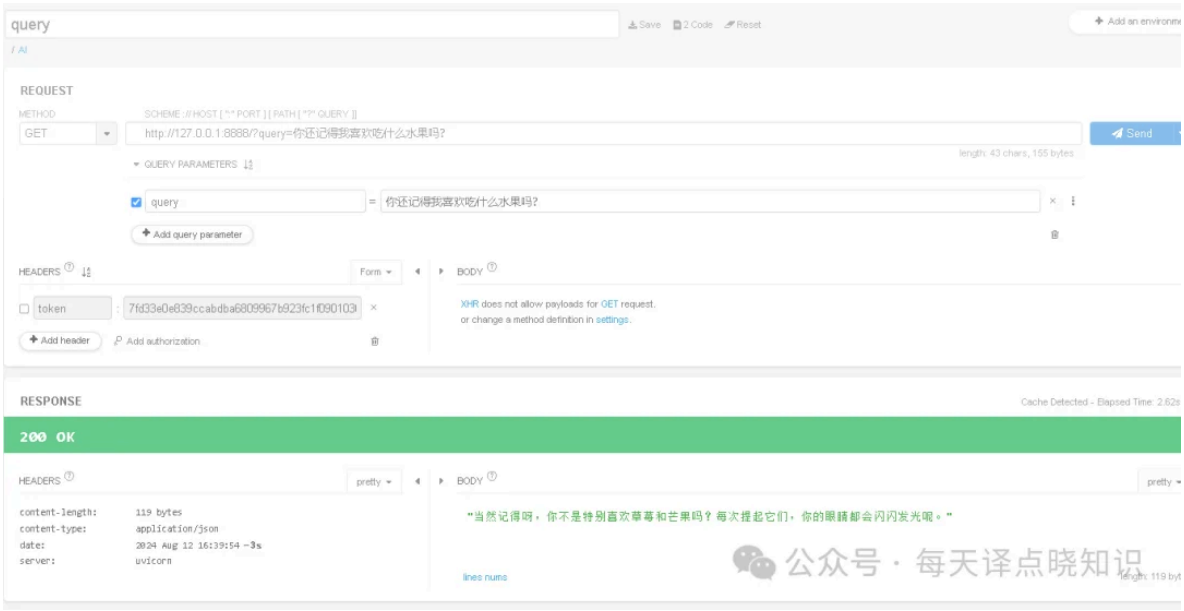


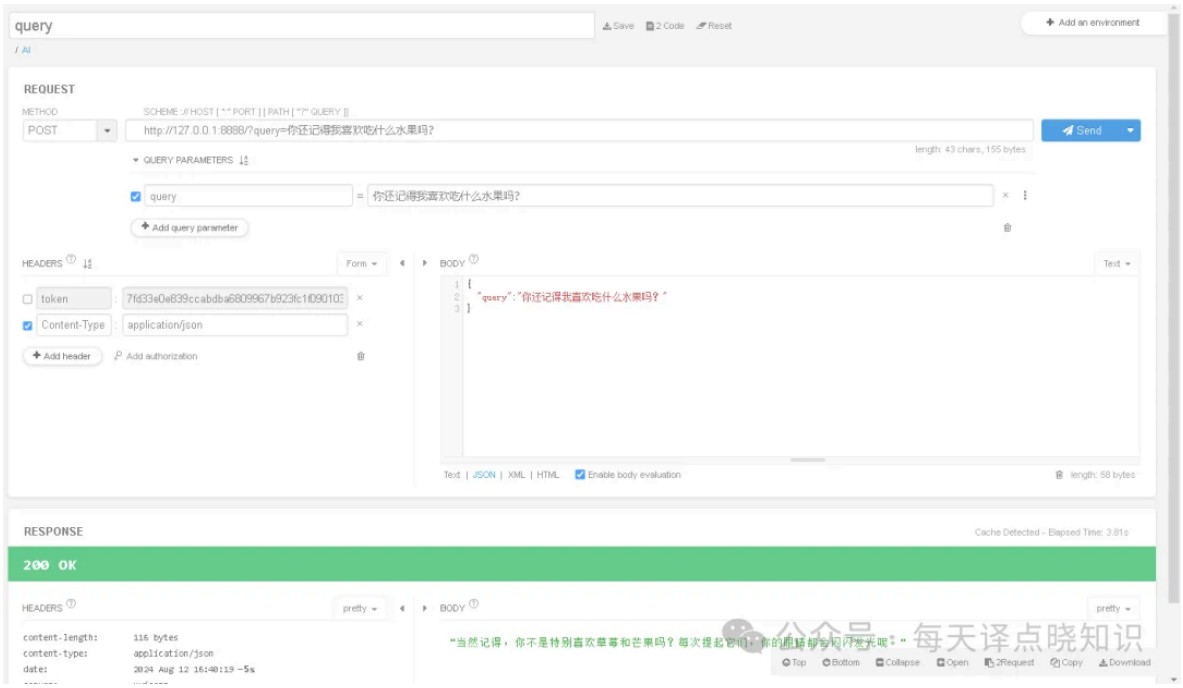
这样，就能够提供对外的 API 接口出来了，接口调用效果如下：





当然，我们也可以使用 Restlet Client 进行 Rest API Testing：



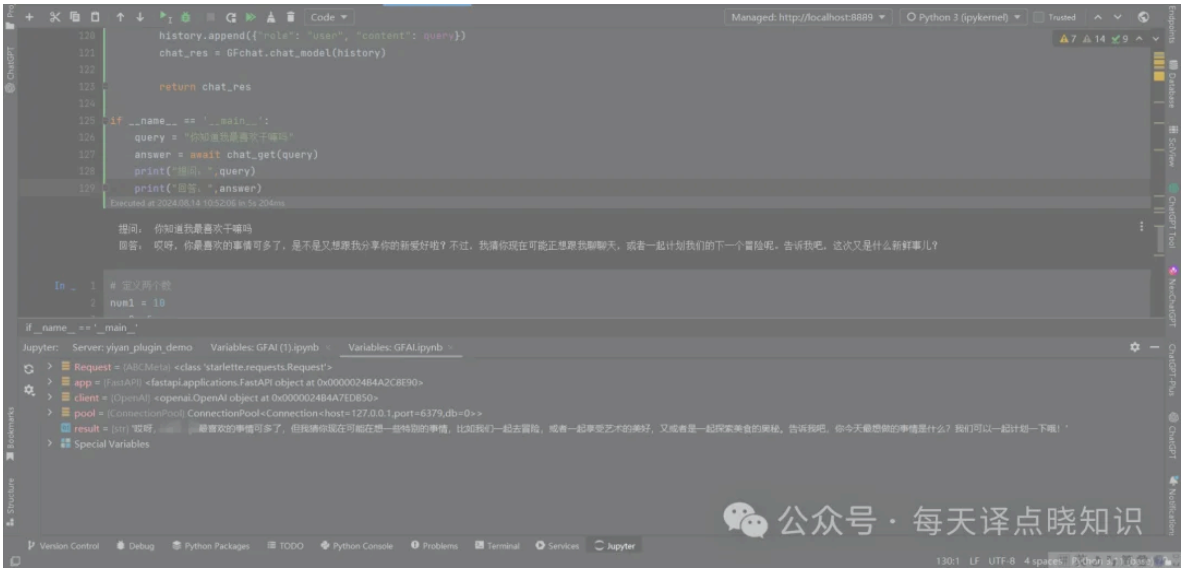


No.3 智能问答调试

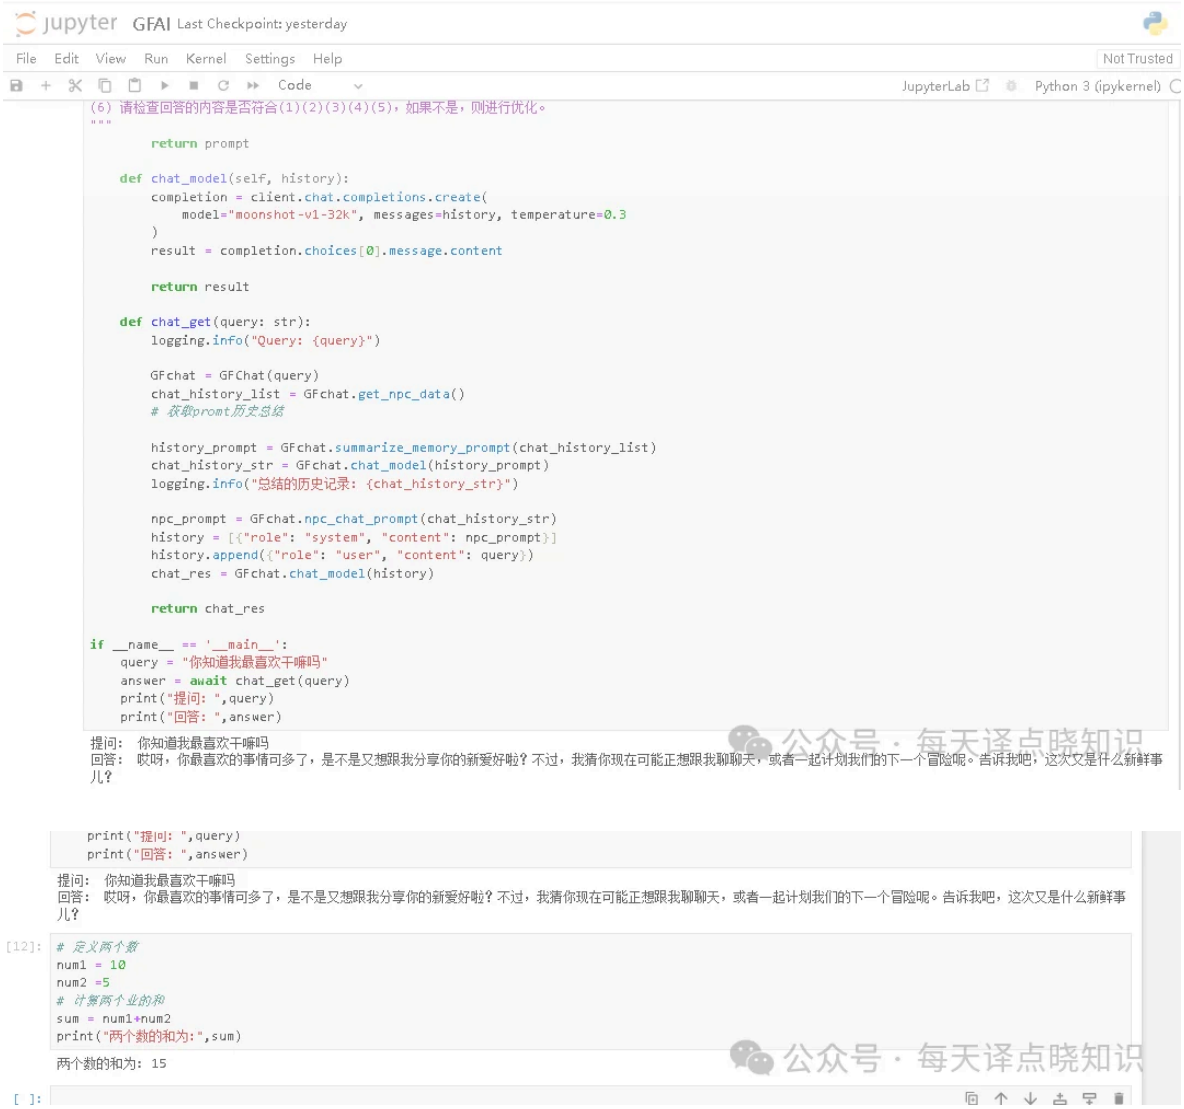
这里，我们给定一些日常话题来看看咨询效果：



因为在之前调试的时候，有些问题已经有了记忆属性，但还是能够看出 AI 可以精准理解我们的输入意图。



对应在 Jupyter Notebook 中的回答效果如下：



看到这里，想必大家对线上众多智能体产品使用体验，不再感觉很神秘了吧。

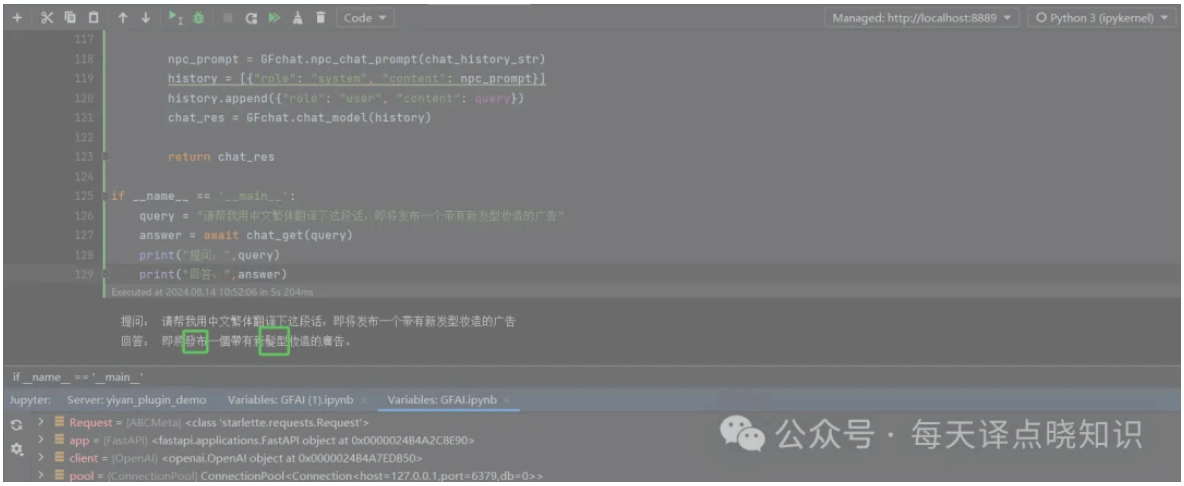
我们来将提问 结合语义、语境升华 一下：

接下来，以一个真实案例嵌入：多语–国际化，这里选择一个在多语言环境存在不一样词性的词。



输入请帮我用中文繁体翻译下这段话：

```
1 即将发布一个带有新发型妆造的广告
```



对应 Jupyter Notebook 回答：可以看出对“发”这个词依旧准确地给出了答案。



诚然，Encoder-Decoder的过程：从信息的压缩与抽象->信息的还原与创造。

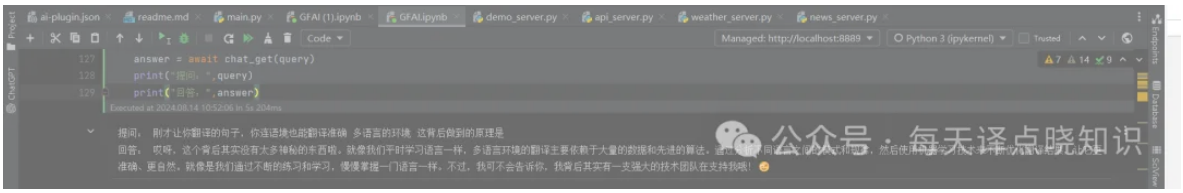
```
Encoder 它能够将图像、文本等复杂数据转换成高维向量空间中的特征表示，这些特征既保留了原

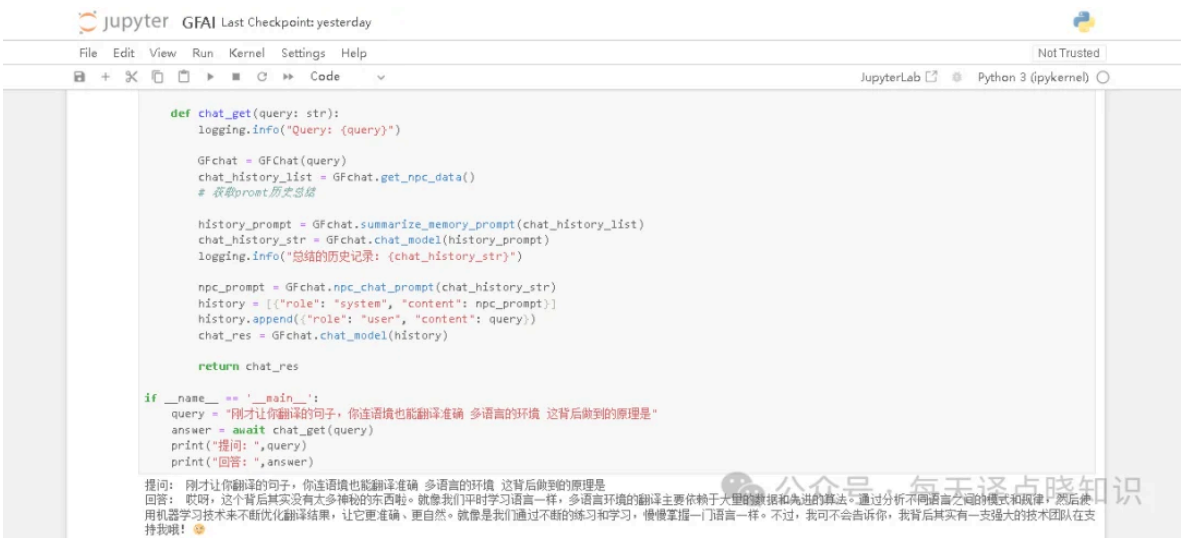
Decoder 它负责将 Encoder 处理后的数据还原回人类可理解的形式，无论是文字、图像还是声音

Encoder-Decoder 架构，这一架构在机器翻译、语音识别、图像生成等众多领域展现出了惊人的

在自动驾驶领域，Encoder-Decoder 架构也被广泛应用于环境感知与决策制定。车辆通过摄像头
```

Ok，now，那我们来继续检测一下上下文联想效果：看看之前咨询的问题，在其背后是如何经过决策并将答案呈现至用户眼前的?





温馨提示：上述case经过多次调试-调优过程，对背后技术实现原理感兴趣的可后台私信一起探讨><

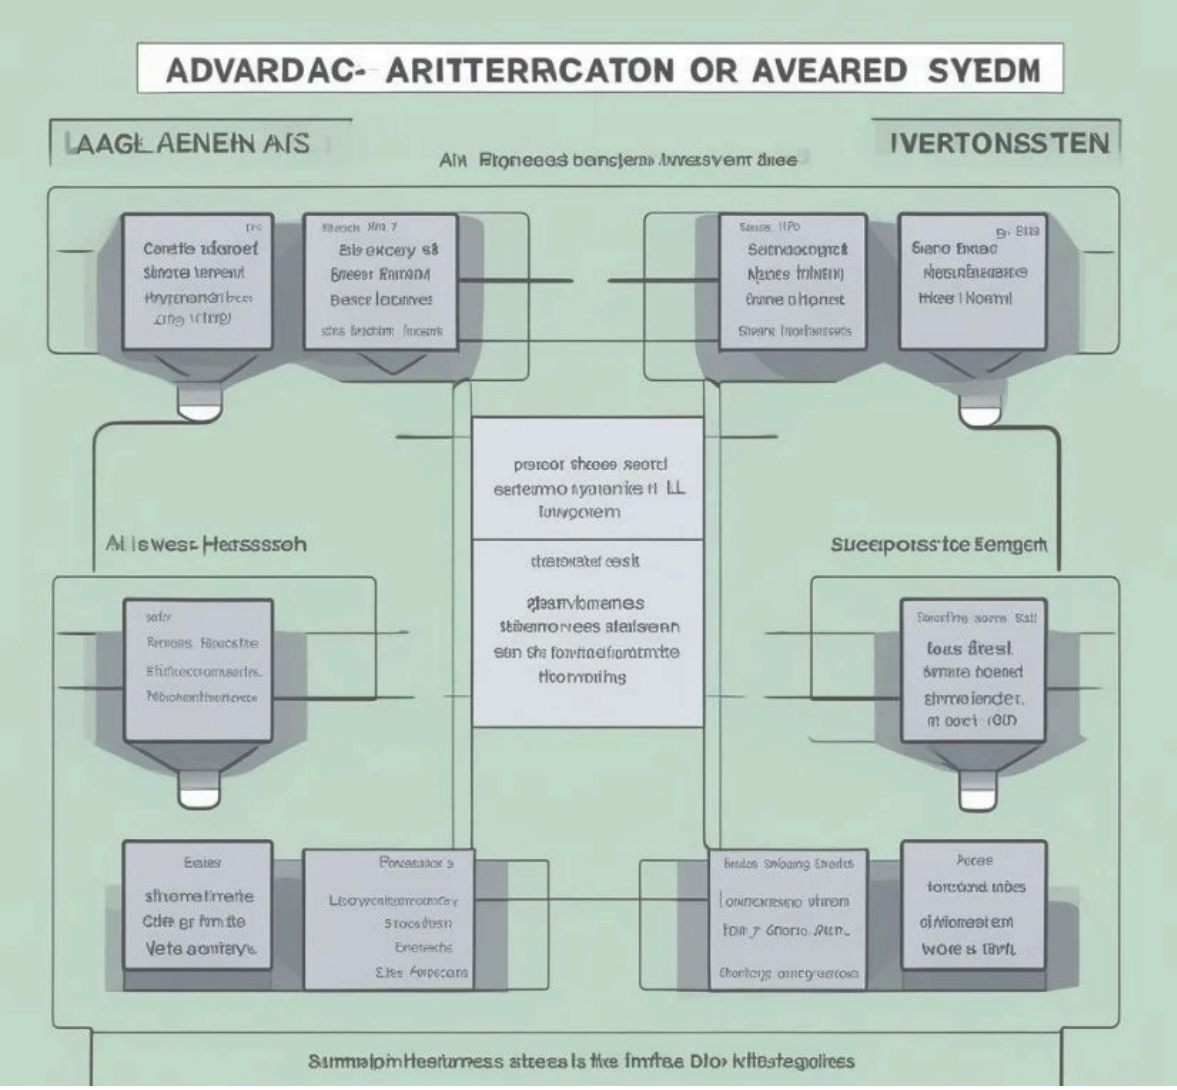
【末尾彩蛋】

```
task1：采用 RAG（Retrieval-Augmented Generation）理念。

我们首先将历史对话记录整合进知识库。接着，通过嵌入技术（embedding）处理
这些记录，并将它们存储于向量数据库（vector store）中。

在接收到查询（query）时，系统会执行搜索匹配，筛选出与查询最相关的文本片段。
这些文本片段随后将与查询一同提交给大型语言模型（LLM），以生成回答。
```

```
8
9  task2：保持对话连贯性、最新信息的实时性。
10 此外，系统会分阶段对对话进行汇总，但最近N条记录将保持独立，不进行汇总，
11 直接用于 LLM 的回答过程中。这样的设计旨在保持对话的连贯性，同时确保最新信息的实时性。
```



对 AI 在各个领域的应用感兴趣？更多关于人工智能在体育领域的应用，想了解更多关于 AI 黑科技的神奇功能？获取最新资讯和技术干货！👇👇👇

从知识中来，到知识中去!

点击下方卡片 关注我

↓↓↓



每天译点晓知识

源自于系统架构设计师、数据库系统认证工程师的一点分享，专注于互联网系统架构，国...

73篇原创内容

公众号

>>>后台回复：AI 进阶，[AI 赋能企业应用实战篇]<<<

往期文章

AI 科普 | 人工智能大模型

Kimi：介绍一种垂类的提示词获取方法！

AI | 从0-1手把手打造一款属于自己的大模型创意应用！

Kimi 进阶版：高考志愿填报，AI 来帮，智能选，未来稳~

AI 有感：智能体 = 提示词工程 + 大模型算力 + 插件类工具?

新一代 AI 智能化搜索：如何在亿万数据海洋中，高效捕捞“宝藏知识”?

Kimi 进阶探索：解锁微信公众号 AI 智能机器人新玩法，轻松打造个性化服务！

Kimi 高阶技巧：指定工作流生成 Markdown 内容，文章大纲、论文材料一键速成！

AI 专栏 31　大模型 24　人工智能 27　AI工具 2

AI 专栏 · 目录

上一篇
在AI里，我的奥运观赛体验还提升了?

下一篇
GLM-4-Flash免费：与你一起共话西游，懂你的“悟空”，谁不想做一回“齐天大圣”！