自建AI编程助手丨本地 Yi-Coder模型 + Cursor 5分钟写一个网页

Original WasmEdge Second State 2024年09月12日 06:36

Yi-Coder[1] 是一个开源的高性能代码语言大模型，为实现高效编程设计。它支持 52 种编程语言，擅长处理需要长上下文理解的任务，例如项目级代码理解和生成。该模型有两种大小（15亿和 90亿 参数），并且提供基础版和聊天版。

本教程中，你将学习如何

- 使用与 OpenAI 兼容的 API 在本地运行 Yi-coder 模型
- 使用 Yi-coder 驱动 Cursor

Cursor 是最热门的 AI 代码编辑器之一。它可以用专门为编码任务训练的 LLM（如 Yi coder）来完成编码辅助任务。你可以将 Yi-coder-9B 配置为 Cursor 的私有 LLM 后端。

用与 OpenAI 兼容的 API 在本地运行 Yi-coder 模型

要获取 Cursor 所需的本地 Yi-coder-9B 的公共 HTTPs endpoint，请按照以下说明操作。

安装开源 Gaia 节点——一组轻量且可移植的 LLM 推理工具。

> Gaia's tech stack is built on top of WasmEdge[2], a WebAssembly-based runtime optimized for serverless computing and edge applications. This setup allows for efficient deployment of Yi-Coder in different environments, providing flexibility and scalability.

```
curl -sSfL 'https://github.com/GaiaNet-AI/gaianet-node/releases/latest/download/install.s
```

然后，使用以下命令行下载并初始化模型。

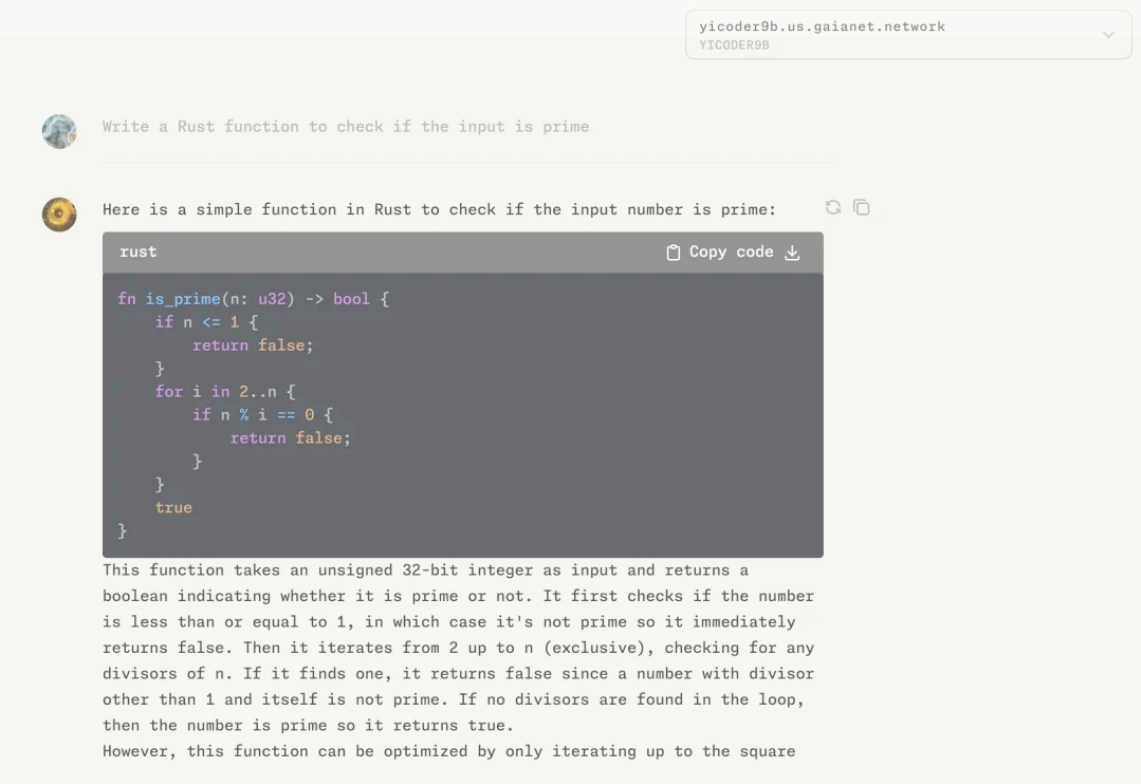
```
gaianet init --config https://raw.githubusercontent.com/GaiaNet-AI/node-configs/main/yi-c
```

最后，使用 `gaianet start` 来运行节点。

```
gaianet start
```

然后你会得到一个 HTTPS URL，像这样 `https://NODE-ID.us.gaianet.network` .

同时，您可以打开浏览器为 **`http://localhost:8080`** 来问有关编程的问题。



> 我们以 8k 上下文窗口启动了 Yi Coder 9b 模型。如果你的机器有较大的 GPU RAM（例如 24GB），则可以将上下文大小一直增加到 128k。较大的上下文大小在编码中特别有用，因为我们可能需要将大量源代码文件塞入 LLM 提示中才能完成复杂的任务。

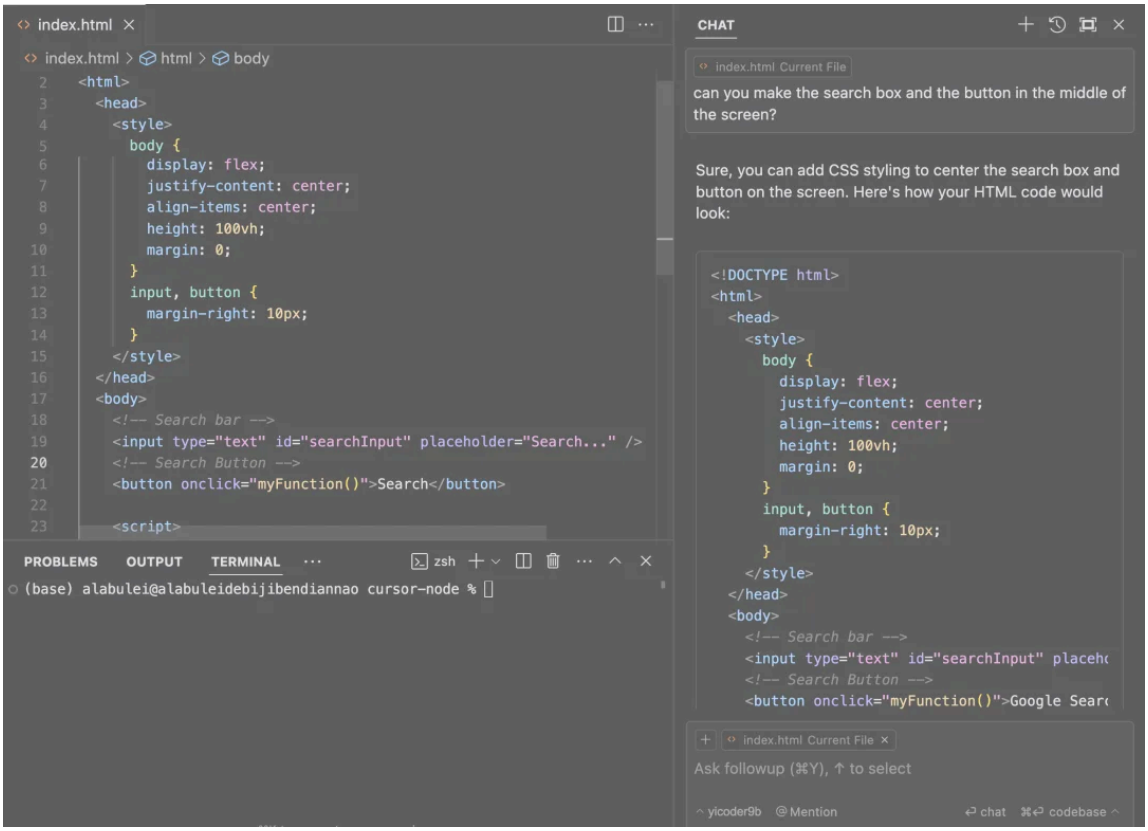
将 Yi-coder-9B 集成到 Cursor

接下来，让我们使用在我们自己的机器上运行的 Yi-Coder-9B 配置 Cursor。

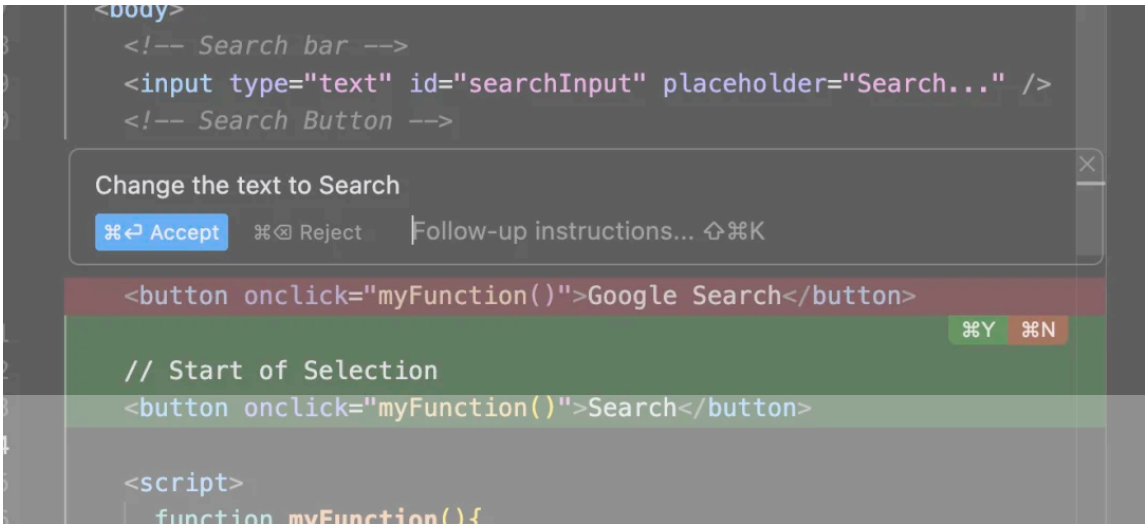
SecondState 4

只需使用你的 Gaia 节点 URL 覆盖 Cursor 的默认 OpenAI URL，修复模型名称和“API 密钥”，就可以开始工作了！请参阅此处[3]的详细说明。

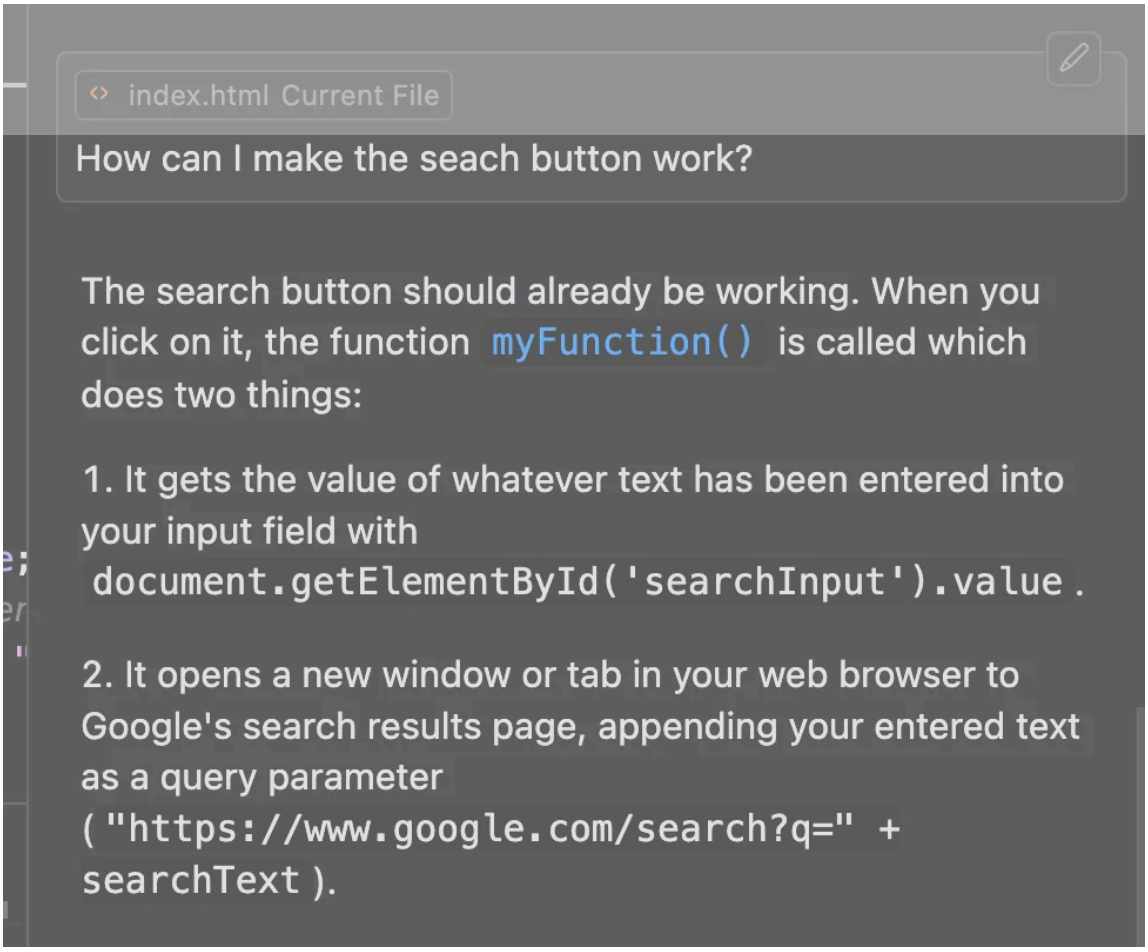
现在，让我们测试 Yi-coder-9b 来编写一个简单的搜索页面。



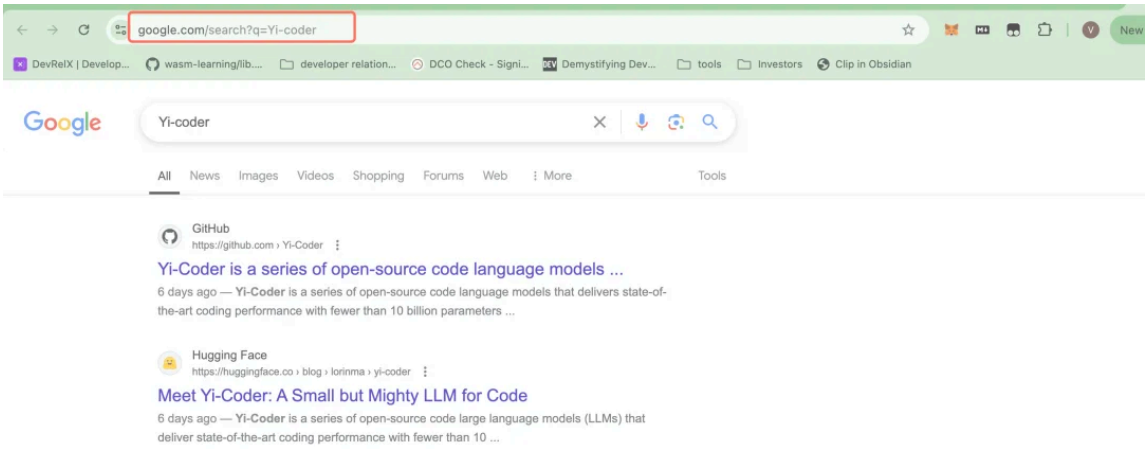
我提示模型生成了一个简单的搜索页面。



然后，我要求 Yi-coder-9b 修改按钮上的文字标签。



Yi-coder-9b LLM LLM 解释了搜索按钮的工作原理。



网页如预期运行！

就这样啦！访问 **LlamaEdge 文档**[4]获取更多信息。加入 **WasmEdge discord**[5] 和我们交流吧！

参考资料

[1] Yi-Coder: *https://huggingface.co/blog/lorinma/yi-coder*

[2] WasmEdge: *https://github.com/WasmEdge/WasmEdge*

[3] 此处: *https://docs.gaianet.ai/user-guide/apps/cursor/#configure-cursor*

[4] LlamaEdge 文档: *https://llamaedge.com/docs/category/drop-in-replacement-for-openai*

[5] WasmEdge discord: *https://discord.com/invite/U4B5sFTkFc*

关于 WasmEdge

WasmEdge 是轻量级、安全、高性能、可扩展、兼容OCI的软件容器与运行环境。目前是 CNCF 沙箱项目。WasmEdge 被应用在 SaaS、云原生，service mesh、边缘计算、边缘云、微服务、流数据处理、LLM 推理等领域。

GitHub：https://github.com/WasmEdge/WasmEdge
官网：https://wasmedge.org/
Discord **群**：https://discord.gg/U4B5sFTkFc
文档：https://wasmedge.org/docs

Read more